

学 期 2021-2022 (2)

# 北京航空航天大學

## 深度学习与自然语言处 理第五次作业

### 基于 Seq2seq 模型的文本生成

院(系)名称	自动化科学与电气工程学院
专业名称	电子信息
学生姓名	蔡尽云
学号	ZY2103501
指导老师	秦曾昌

2022年6月

#### 1 问题描述

基于 Seq2seq 模型来实现文本生成的模型,输入可以为一段已知的金庸小说段落,来生成新的段落并做分析。

#### 2 实验原理

#### 2.1 seq2seq 模型

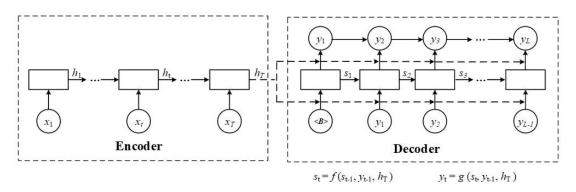
seq2seq 全称为: sequence to sequence ,是 2014 年被提出来的一种 Encoder-Decoder 结构,主要用于机器翻译领域,也正是 seq2seq,将机器翻译提高到了一个新的高度,而 attention 机制,让机器翻译完成了进化。seq2seq 的主要思想是输入一个序列,通过 encoder 编码成一个语义向量 c(context),然后 decoder 成输出序列。这个结构重要的地方在于输入序列和输出序列的长度是可变的。

#### 2.2 Encoder-Decoder

Encoder: seq2seq 的编码器是单层或多层的 RNN(双向),会对输入的文本进行编码 变成一个向量输出。

Decoder: seq2seq 的解码器,也是一个单层或多层的 RNN(非双向),然后根据 context 信息对每一步进行解码,输出对应的文本。

下图是一个经典的 Encoder-Decoder 模型,但其问题是,这个 context 是一个固定长度的向量,表达能力比较有限,所以在这个基础上,又提出了 Attention 机制。



Attention 机制:每步解码都会根据当前状态对 encoder 的文本进行动态权重计算,然后对权重进行归一化。得到归一化后,再算出一个当前加权后的 context,作为 decode 的 context。这样处理后的表达能力就会就会更强一些。

#### 2.3 模型应用领域

首先作为为机器翻译问题为出发点提出来的 seq2seq模型,机器翻译的准确率因为该模型的提出而有了较大的提升。作为 seq2seq模型研发团队,Google Brain 团队在 2014年的文章的应用案例中对 LSTM 的隐藏结点做了主成分分析。其次 seq2seq模型因为突破了传统的固定大小输入问题框架,因而除了翻译场景,还被用于智能对话与问答的实现等。

#### 3 实验设计

本次实验以天龙八部作为输入。

- 1、数据预处理: 删去所有的隐藏符号, 删除所有的非中文字符, 不考虑上下文关系的前提下删去所有标点符号。以 jieba 库对中文语料进行分词。
- 2、模型训练:在利用 Jieba 分词库对输入语料进行分词后,仿照第四次作业一样,利用 Word2Vec 模型对输入语料进行词嵌入,之后利用 torch 框架进行 LSTM 神经网络训练。
  - 3、读取测试语料: 在模型训练完毕后, 读取测试语料, 并进行简单的预处理。
  - 4、测试输出:使用已经训练好的模型对输入语料进行 Sequence to Sequence 输出。

#### 4 结果分析与总结

1、输入语料:

段誉一颗心几乎要从口中跳将出来,问道:"那你表哥怎麽样?你一直…一直喜欢慕容公子的。"王语嫣道:"他却从来没将我放在心上。我直至此刻方才知道,这世界上谁是真的爱我、怜我,是谁把我看得比他自己性命还重。"段誉颤声道:"你是说我?"

王语嫣垂泪说道:"对啦!我表哥一生之中,便是梦想要做大燕皇帝。本来呢,这也难怪,他慕容氏世世代代,做的便是这个梦。他祖宗几十代做下来的梦,传到他身上,怎又能盼望他醒觉?我表哥原不是坏人,只不过为了想做大燕皇帝,别的甚麽事都搁在一旁了。"

段誉听她言语之中,大有为慕容复开脱分辨之意,心中又焦急起来,道:"王姑娘,倘若你表哥一旦悔悟,忽然又对你好了,那你...你...怎麽样?"

王语嫣叹道:"段郎,我虽是个愚蠢女子,却决不是丧德败行之人,今日我和你定下三生之约,若再三心两意,岂不有亏名节?又如何对得起你对我的深情厚意?"

#### 2、输出结果:

段誉结结结巴的问道:"段公子,却从未对你…我…我喜欢慕容公子的。"段誉乍闻好音, 兀自不信,问道:"是说,我虽是个愚蠢女子,我虽只你是丧德败之意,岂不有亏名节??" 段誉对自己都没有死,事出来业会使坏。她自幼痴恋表兄,始终得到生,不由得娇羞羞人的我,我愿终身处,实在又是污泥,中陷下,忍不住段誉听她身子,我虽然又能成为夫妻,但死而同穴,也总算得遂了了,想到的是个情厚意?"段誉颤声道:"段公子段誉结结结住,问道:"...我...我喜欢慕容公子,却...我喜欢慕容公子的。"

#### 3、分析:

可以看出输出的结果虽然和金庸的文风很像,但仍然出现了段誉说"我喜欢慕容公子"、 "我虽是个愚蠢女子"这种与原文不符的内容,可能是因为"我"、"你"两个字的频率相近,输 出时出现了混用,内容也出现了一些重复。总体来说还是一些读不通的"金庸"式奇怪内容, 尚存不少改进的空间。

#### 5 代码链接

见 https://github.com/ErrricCai/DL-NLP/tree/main/HW5

参考:

https://blog.csdn.net/gzmfxy/article/details/78691048

 $\underline{https://blog.csdn.net/shzx\_55733/article/details/117338742?spm{=}1001.2014.3001.5502$